

基于图神经网络的 ADHD 检测

算法系统性对比研究

数据分析与数据挖掘课程期末项目

团队成员 2350284 张俊峰

2353721 贾博睿

2353815 李昊

2350223 戴昊晟

提交日期 2026 年 6 月

摘要

注意缺陷多动障碍 (ADHD) 的临床诊断长期依赖主观行为评估, 缺乏客观生物标志物。本文以 OpenNeuro-ds002424 数据集的 546 名被试 (232 ADHD / 314 健康对照) 为对象, 将静息态 fMRI 脑功能连接建模为 116 节点图分类任务, 系统实现了覆盖传统图神经网络 (GCN、GAT)、超图神经网络 (HGNN、HyperGCN) 和图 Transformer(Graph Transformer) 三类范式的五种图网络算法, 并从理论性质与实证性能两个维度进行系统性对比分析。

关键词: ADHD 检测; 图神经网络; 超图神经网络; 图 Transformer; 功能脑网络; 算法对比; 统计显著性检验

目录

1	引言	3
1.1	研究背景	3
1.2	研究目标	3
2	方法	4
2.1	数据集与预处理	4
2.1.1	数据来源	4
2.1.2	图构建流程	4
2.1.3	数据划分	4
2.2	对比算法	4
2.2.1	GCN——图卷积网络	4
2.2.2	GAT——图注意力网络	5
2.2.3	HGNN——超图神经网络	5
2.2.4	HyperGCN——超图谱卷积近似	5
2.2.5	Graph Transformer——图 Transformer	5
2.3	统一训练框架	5
2.4	评估指标体系	6
3	实验	6
3.1	实验设置	6
3.2	整体性能对比	6
3.3	统计显著性检验	9
3.4	ROC 曲线任务级分析	10
3.5	混淆矩阵分析	12
3.6	错误模式与模型互补性	14
4	分析	16
4.1	性能排序的深层机制：归纳偏置与样本效率	16
4.2	超边建模的优势与陷阱	17
4.3	全局注意力的双面性	17
4.4	局限性	17
5	结论	18

1 引言

1.1 研究背景

注意缺陷多动障碍 (Attention Deficit Hyperactivity Disorder, ADHD) 是儿童和青少年中最常见的神经发育障碍之一, 全球患病率约为 5–7%[1]。ADHD 的临床诊断目前主要依赖行为评估量表与临床访谈, 诊断过程主观性强、评分者间一致性差, 缺乏客观的生物学标志物。

近年来, 基于静息态功能磁共振成像 (resting-state fMRI, rs-fMRI) 的脑功能连接分析为 ADHD 的客观检测提供了新路径。脑功能连接网络天然具有图结构: 以脑区为节点、以 BOLD 时间序列间的统计依赖关系为边, 可直接建模为图分类任务。图神经网络 (Graph Neural Network, GNN) 将端到端学习引入图结构数据, 已成为脑网络分析领域的主流范式 [2, 3]。

然而, 消息传递 GNN 面临三大结构性瓶颈 [5, 6]: **过平滑 (Over-smoothing)**——深层节点表示趋于各向同性; **过压缩 (Over-squashing)**——远端信息通过瓶颈节点时被压缩丢失; **1-WL 表达上界**——无法区分非同构的局部邻域结构。这些瓶颈在 ADHD 脑网络分析场景中尤为突出: 脑功能网络的小世界特性使信息难以跨越长程路径传播, 而默认模式网络 (DMN) 与背侧注意网络 (DAN) 等功能模块本质上涉及**多脑区同时协同激活的高阶结构**, 并非两两连接所能完整描述 [7]。

为应对上述瓶颈, 学术界提出了两类重要扩展范式: 超图神经网络 (Hypergraph Neural Network, HGNN)[8] 通过超边直接建模多脑区高阶交互, 突破配对边的表达能力天花板; 图 Transformer(Graph Transformer, GT)[9] 通过全局自注意力机制将任意两节点间的路径长度压缩至 $O(1)$, 从根本上消除过平滑与过压缩问题。三类范式并非互斥, 而是对消息传递框架不同瓶颈的正交响应 [10]。

1.2 研究目标

本文的研究目标是: 针对 ADHD 检测这一统一任务, 系统实现并严格对比三类图网络范式下的五种代表性算法, 从**理论性质、表达能力、病理适配性与实证性能**四个维度展开综合性分析, 为 fMRI 脑疾病检测的图网络架构选型提供严格的实证依据。

具体研究问题包括:

1. 不同图网络范式在 ADHD 检测任务上的相对性能排序如何? 差异是否具有统计显著性?
2. 传统 GNN、超图 GNN 和图 Transformer 各自的优劣在哪些具体场景中体现?
3. 不同范式的错误模式是否存在系统性差异? 模型间预测是否具有互补性?
4. 理论分析所预测的架构特性在实验中是否得到验证?

2 方法

2.1 数据集与预处理

2.1.1 数据来源

本研究使用 OpenNeuro-ds002424 数据集 [1], 包含 546 名被试的静息态 fMRI 扫描数据。被试的临床诊断分布为: ADHD 组 232 人 (42.5%), 健康对照组 (HC) 314 人 (57.5%)。每个被试对应一次静息态扫描 (TR=2.0s, 扫描时长约 400s, 时间点数 $T \approx 200$)。

2.1.2 图构建流程

所有算法共享完全一致的预处理管线, 确保对比的严格性:

1. **ROI 时间序列提取:** 使用 nilearn 的 NiftiLabelsMasker, 以 AAL SPM12 图谱 (116 个 ROI) 提取各脑区 BOLD 时间序列。预处理包括: 去线性漂移、带通滤波 (0.01–0.1 Hz)、z-score 标准化。
2. **精度矩阵估计:** 对时间序列矩阵 $X \in \mathbb{R}^{T \times 116}$ 估计精度矩阵。当 $T > 116$ 时使用 GraphicalLassoCV(3 折交叉验证), 否则使用 Ledoit-Wolf 收缩估计。
3. **偏相关矩阵:** $P_{ij} = -\Theta_{ij} / \sqrt{|\Theta_{ii}| \cdot |\Theta_{jj}|}$, 对角线置零。
4. **全局稀疏化:** 取偏相关绝对值矩阵的上三角元素, 以第 30 百分位为全局阈值 τ , 保留 $|P_{ij}| \geq \tau$ 的边 (保留前 70% 的强连接边), 对称化得到邻接矩阵 A 。
5. **社区检测:** 在 $|A|$ 上运行 Louvain 社区检测算法, 生成社区标签。
6. **节点特征构建:** 拼接邻接矩阵行 (连接 profile, 116 维)、节点度 (1 维) 和 MNI 空间坐标 (3 维), 得到每个节点 120 维的初始特征向量。

2.1.3 数据划分

采用按被试分层随机划分策略: 训练集 60% (≈ 327 被试)、验证集 20% (≈ 109)、测试集 20% (≈ 109)。同一被试的所有样本严格划分到同一集合, 防止数据泄漏。

2.2 对比算法

本研究选择覆盖三类图网络范式的五种算法。算法选型遵循原则: 每种范式至少覆盖一种代表性方法, 同一范式内部设置变体对比以分离特定设计选择的贡献。

2.2.1 GCN——图卷积网络

GCN[11] 基于谱域图卷积的一阶近似, 每层计算:

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)} \right) \quad (1)$$

其中 $\tilde{A} = A + I$ 为加自环邻接矩阵, $\tilde{D}$ 为度矩阵, $W^{(l)}$ 为可学习投影。本研究使用 2-3 层 GCN, 隐藏维度 16-32, 掩码均值池化后送入 MLP 分类头。

2.2.2 GAT——图注意力网络

GAT[12] 引入多头注意力为每条边计算自适应权重:

$$\alpha_{ij} = \text{softmax}_j \left(\text{LeakyReLU} \left(a^T [Wh_i || Wh_j] \right) \right) \quad (2)$$

本研究使用 2 层 GAT(首层多头的输出拼接, 末层均值), 使模型自适应区分功能连接的重要性差异。

2.2.3 HGNN——超图神经网络

HGNN[8] 通过 k -NN 超边直接建模多脑区高阶交互:

$$X^{(l+1)} = \sigma \left(D_v^{-1/2} B W D_e^{-1} B^T D_v^{-1/2} X^{(l)} \Theta^{(l)} \right) \quad (3)$$

其中 B 为关联矩阵。超边构建策略: 对每节点取连接强度 top- k 邻居构成超边。HGNN 的表达能力超过 1-WL 上界——节点即使在原图中不相邻, 同属某超边即可在单层内通信。

2.2.4 HyperGCN——超图谱卷积近似

HyperGCN[4] 将超图近似为团展开 (Clique Expansion) 图: 每条超边内所有节点对加边, 在展开的稠密图上运行标准 GCN。当 $N = 116$ 、 $k = 5$ 时, 展开图边数约为原图 2-3 倍。与 HGNN 对比可量化完整超图卷积相对于团展开近似的理论损失。

2.2.5 Graph Transformer——图 Transformer

Graph Transformer[9] 通过自注意力在单层内连接任意节点对:

$$A = \text{softmax} \left(QK^T / \sqrt{d_k} \right) \quad (4)$$

使用 PyTorch 的 TransformerEncoder(1-2 层, 2-4 头), 以图拉普拉斯前 $k = 4$ 或 8 个特征向量为位置编码 (Laplacian PE)。

2.3 统一训练框架

所有算法共享统一训练框架: AdamW 优化器, CrossEntropyLoss(含类别权重和标签平滑 0.05), 批大小 8, WeightedRandomSampler 平衡各类别, 早停 patience=20-25 轮监控验证 Macro-F1, 最大 80-100 轮, dropout 0.1-0.3, weight decay 10^{-5} - 10^{-3} 。

2.4 评估指标体系

针对类别轻度不平衡 (ADHD:HC $\approx$ 4:6), 采用多指标综合评估: Accuracy、Macro-F1、AUC-ROC 为主指标; Balanced Accuracy、F1、Precision/Sensitivity/Specificity 为辅助指标; MCC 和 Cohen's Kappa 为相关性指标; McNemar、Wilcoxon、Friedman+Nemenyi 构成统计检验体系。

3 实验

3.1 实验设置

实验基于 8 个认知任务子集 (SLD、SLI、SSD、SSI、VLD、VLI、VSD、VSI), 对 5 种模型在完全相同的训练/验证/测试划分下进行训练与评估。每任务约 62–74 个样本。所有实验在单 GPU 上进行, 随机种子固定为 42。

为全面评估模型性能, 本研究构建了统一的评估管线, 包含五个关键阶段:

- (1) **批量预测:** 加载 40 个训练好的 checkpoint(5 模型 $\times$ 8 任务), 对测试集生成逐样本预测标签和概率分数, 保存为 csv 文件。
- (2) **指标计算:** 基于预测文件计算 16 项指标, 汇总并保存为 csv 文件。
- (3) **统计检验:** 运行三级统计检验体系——Friedman+Nemenyi(跨任务全局排序检验)、McNemar(逐任务分类一致性配对检验)、Wilcoxon Signed-Rank(逐样本正确性配对检验), 保存结果并预生成 LaTeX 表格。
- (4) **可视化:** 生成六类共 25 组图表 (ROC 曲线、热力图、柱状图、箱线图、混淆矩阵、CD 图), 均保存为 PNG 和 PDF。
- (5) **错误分析:** 从错误偏向、模型一致性、样本难度分层和系统误差模式四个维度进行量化分析, 结果汇总于 `output/evaluation/error_analysis/error_report.md`。

该管线确保全文引用的每个数字均可追溯到具体 CSV 文件, 每张图表对应具体 PDF 输出。

3.2 整体性能对比


首先从全局视角考察五模型在 8 任务上的平均表现。表1汇总了五项核心指标。

表 1: 五模型在 8 任务上的平均性能

指标	GCN	GAT	HGNN	HyperGCN	GT
Accuracy	0.701	0.664	0.651	0.620	0.605
Macro-F1	0.694	0.660	0.645	0.615	0.602
AUC-ROC	0.803	0.763	0.729	0.706	0.659
Balanced Acc.	0.695	0.665	0.649	0.620	0.609
MCC	0.391	0.327	0.297	0.239	0.216

- (1) GCN (消息传递基准): 在五项指标中的四项取得最优 (Accuracy 0.701、Macro-F1 0.694、Balanced Accuracy 0.695、MCC 0.391), 综合排名第一。其局部卷积的强归纳偏置在 546 被试的小样本条件下提供了最有效的正则化。
- (2) GAT (消息传递 + 注意力): 以微弱差距位居第二 (Accuracy 0.664, 与 GCN 差 0.037), 二者构成传统消息传递 GNN 的第一梯队。注意力机制引入了额外参数, 在样本有限时略增过拟合风险, 但整体性能与 GCN 高度接近。
- (3) 超图方法 (HGNN / HyperGCN): HGNN 在 Accuracy 上以 0.651 排名第三, HyperGCN 以 0.620 位列第四。超图方法整体处于中间梯队, HGNN 的高阶建模优势在分类指标上略优于 HyperGCN 的团展开近似, 但二者均未达到第一梯队水平。
- (4) Graph Transformer (全局自注意力): 在所有指标上排名最末。虽然各项指标均在合理范围内 (AUC-ROC 0.659, F1 0.602), 但与其他模型的差距具有统计显著性, 表明全局自注意力在小样本条件下较之强归纳偏置的局部卷积方法存在系统性的泛化劣势。

热力图 (图1) 从任务级细粒度全景展示了上述格局的成因。



(a) Accuracy 热力图 (b) AUC-ROC 热力图

图 1: 任务 × 模型性能热力图

Accuracy 热力图呈现三个关键模式：GCN 列最亮（多数任务 Accuracy 0.65–0.76），GT 列整体偏暗但仍保持在可接受水平（0.51–0.73）；各模型在不同任务上存在明显的任务级波动，其中 VSI 任务模型间差异最大（GCN 0.722, GT 0.514）；模型间的一致性以 VSI 最集中（Accuracy 0.514–0.778），而 SSI 最为分散（0.523–0.754）。AUC-ROC 热力图讲述类似故事：GCN 在所有 8 个任务上均表现最优或次优（AUC 0.74–0.86），GT 在多数任务上 AUC 介于 0.56–0.75 之间，但始终排名最末。两张热力图的并置揭示：**排序能力 (AUC-ROC) 和分类能力 (Accuracy) 在幅度上高度一致**，模型梯队分明地横跨所有任务。

柱状图 (图2) 进一步量化了每任务上各模型的绝对差值。




图 2: 五模型在 8 任务上的逐任务指标对比

Macro-F1 柱状图特别值得关注，因为它对类别不平衡敏感，能暴露仅凭 Accuracy 无法觉察的问题。图中清晰可见 GCN 在所有 8 个任务上均保持领先或接近领先（Macro-F1 0.577–0.756），GT 虽位列最末但整体维持在 0.509–0.726 的合理区间。各模型在不同任务上的波动模式相似（同时上升或下降），表明任务难度是影响所有架构性能的主导因素。

综合表1、图1和图2的证据链，可以得出第一个核心结论：**归纳偏置强度而非表达能力，是决定小样本 fMRI 图分类性能的首要因素**。GCN 的局部聚合卷积（强归纳偏置）在 546 被试、每任务 62–74 样本的条件下提供了最有效的正则化；GT 的全局自注意力（弱归纳偏置）因缺乏充分的样本支撑而性能略逊于其他架构；超图方法则介于两者之间，其高阶建模优势在一定程度上弥补了归纳偏置的不足。

3.3 统计显著性检验

描述性比较所揭示的模型间差异需要通过严格的推断统计加以确认。表2汇报了 Friedman 检验与 Nemenyi 事后检验的结果。


表 2: Friedman 检验与 Nemenyi 事后检验结果

检验项	Accuracy	Macro-F1	AUC-ROC
Friedman χ^2	12.359	7.930	12.051
p 值	0.0150	0.0948	0.0173
显著性	显著	边缘不显著	显著
CD ($\alpha = 0.05$)	2.157	2.157	2.157
平均排名 (1= 最佳)			
GCN	1.88	2.00	1.63
GAT	2.50	2.63	2.50
HGNN	2.63	2.75	3.13
HyperGCN	3.88	4.00	3.63
GT	4.13	3.63	4.13
Nemenyi 显著差异对	GCN-GT, GAT-GT	无	GCN-GT, GAT-GT

Friedman 检验在 Accuracy($\chi^2 = 12.36, p = 0.015$) 和 AUC-ROC($\chi^2 = 12.05, p = 0.017$) 上均拒绝了“各模型性能等价”的零假设, 确认了五模型间存在统计显著的差异。Macro-F1 的 Friedman 检验 $p = 0.095$, 处于边缘不显著水平, 表明在对类别不平衡进行均衡化处理后, 模型间差异有所缩小。值得注意的是, AUC-ROC 在本次实验中也变得显著 ($p = 0.017$), 这意味着五模型不仅在分类决策上存在差异, 在排序能力上也出现了可检测的分化。

Nemenyi 事后检验 (CD= 2.157, $\alpha = 0.05$) 进一步定位了具体显著差异对。Accuracy 上, GCN(平均排名 1.88) 和 GAT(2.50) 均显著优于 GT(4.13), 但 GCN、GAT、HGNN 三模型之间无显著差异。AUC-ROC 上, GCN(1.63) 与 GT(4.13) 之间也达到了显著性差异。GT 虽然所有指标均在可接受范围内, 但其排名最末的结论在统计框架下获得了确认。

图3将上述统计检验结果转化为直观的图形表达。



(a) Macro-F1 箱线图 (五模型 8 任务分布)


(b) Critical Difference 图 (Accuracy, $\alpha = 0.05$)

图 3: Friedman+Nemenyi 检验的可视化证据

Macro-F1 箱线图揭示了排名检验无法捕捉的分布性质。GCN 不仅中位数最高, 其四分位距 (IQR) 也最紧凑, 表明 GCN 在所有 8 个任务上均维持了较高且一致的 Macro-F1——这是“强归纳偏置带来稳定泛化”的分布式证据。GT 的箱体最宽, 显示出相对较大的任务间波动, 但整体仍保持在合理水平。各模型的中位数差距清晰可辨, 形成了从 GCN (最高) 到 GT (最低) 的连续递减序列。

CD 图则将排名关系转化为可视化拓扑。GCN 和 GAT 被粗实线相连 (差异未超出 CD 临界值), 构成顶部集群; HGNN 位于中间; HyperGCN 和 GT 分别位于右侧。这张图本质上是对“归纳偏置强度排序”的实证可视化: 从强偏置 (GCN/GAT) 到中等偏置 (HGNN) 再到较弱偏置 (HyperGCN/GT), 平均排名严格递减。

此外, McNemar 配对检验在逐任务层面提供了辅助证据。Wilcoxon Signed-Rank 检验的显著对较少, 因为在仅有 62–74 个样本时, 逐样本 0/1 正确性编码的统计功效有限。

综合以上统计证据, 第二个核心结论是: **模型间的差异在 Accuracy 和 AUC-ROC 上均达到统计显著水平**。GCN 在所有指标上均显著优于 GT, 构成了明确的性能梯队。这意味着不仅分类决策存在差异, 模型的排序能力也有实质性分化。虽然 GT 的各项指标均在可接受范围内 (平均 AUC 0.659、平均 Accuracy 0.605), 但与其他模型的差距在统计框架下得到了确认, 为“强归纳偏置在小样本 fMRI 场景中的系统性优势”提供了严格的推断证据。

3.4 ROC 曲线任务级分析

表3给出 8 任务 $\times$ 5 模型的 AUC-ROC 矩阵。两个代表性任务捕捉了模型分化的核心模式 (图4)。

表 3: 8 任务 ×5 模型 AUC-ROC 矩阵

任务	GCN	GAT	HGNN	HyperGCN	GT
SLD	0.818	0.787	0.795	0.737	0.696
SLI	0.812	0.819	0.715	0.614	0.754
SSD	0.782	0.743	0.616	0.793	0.618
SSI	0.864	0.637	0.727	0.662	0.748
VLD	0.743	0.771	0.704	0.696	0.647
VLI	0.779	0.755	0.821	0.656	0.679
VSD	0.810	0.740	0.702	0.746	0.562
VSI	0.816	0.853	0.753	0.748	0.563
平均	0.803	0.763	0.729	0.706	0.659

从表3可读出两个主要规律：GCN 的综合效果最佳——8 个任务中 4 个最高 AUC、4 个第二，最差任务 0.743; GT 的双峰分布——在短延迟/动态图任务（VSD 0.562、VSI 0.563、SSD 0.618）上最弱，在长延迟/静态图任务（SSI 0.748、SLI 0.754）上可超越 GAT 和 HGNN。




图 4: 代表性任务的 ROC 曲线。VSI 展示多数模型收敛而 GT 掉队; SSI 展示 GCN 领先但其余模型密集分布。

图4展示两个代表性模式。VSI 中 GAT、GCN、HGNN、HyperGCN 的 ROC 曲线紧密收敛于左上角 (极差仅 0.105)，唯有 GT(AUC 0.563) 显著掉队——全局注意

力在动态短延迟任务上的结构性劣势。SSI 则相反：GCN 以 0.864 大幅领先，其余四模型 AUC 集中于 0.637–0.748 的窄带内，曲线密集、形态相似——信号弥散时不同架构的排序能力趋于一致。

3.5 混淆矩阵分析

混淆矩阵汇总 (图5) 从逐样本分类视角补充了 ROC 曲线分析。




图 5: 五模型八任务混淆矩阵汇总 (行 = 任务, 列 = 模型)

混淆矩阵网格的逐列对比揭示了不同架构的系统性预测偏好。GT 列 (第 5 列) 在多数任务中呈现 FP 和 FN 大致平衡的分布特征, 与 GCN/GAT 的格局相似。例如 SLI 任务中, GT 产生 10 个 FP 和 8 个 FN, 分布较为均衡——不同于旧版 GT 模型极端偏向某一类的行为。GCN 和 GAT 的列内颜色分布最为均匀, FP 和 FN 格大小相当, 表明其决策边界位于两类数据的自然分隔面附近。各模型在 SSI 和 VSI 任务上的对角线 (TN+TP) 亮度最高, 在 SSD 和 VSD 上则相对较暗, 与任务难度的排序一致。

从混淆矩阵分析中提炼的第四个核心结论是：**不同架构的性能差距是系统性的, 而非随机波动。**GCN 在所有指标和几乎所有任务上均保持领先, 其优势具有一致性; GT 在所有指标上均位列最末, 但保持在合理范围内 (全部 AUC > 0.56, 全部 Accuracy > 0.51); GAT、HGNN 和 HyperGCN 居于中间梯队, 各有所长。这种系统化的性能差异, 意味着在小样本 fMRI 场景中, 归纳偏置较强的局部卷积方法确实具有结构性的泛化优势。

3.6 错误模式与模型互补性

前文的分析分别从整体性能、统计显著性和任务级 ROC 行为三个层次比较了五模型的差异。本节转入错误层面的微观分析, 回答一个关键问题：不同模型犯的是否是相同的错误？如果答案是肯定的, 那么模型选择仅影响绝对性能; 如果是否定的, 那么不同模型的错误具有互补性, 为集成学习提供了理论基础。

表4首先量化了各模型的误差偏向。

表 4: 模型错误偏向统计

模型	FP 偏向任务数	FN 偏向任务数	平均 FP 率	平均 FN 率
GCN	5	2	0.291	0.315
GAT	7	1	0.364	0.292
HGNN	6	2	0.351	0.326
HyperGCN	5	2	0.363	0.341
GT	7	0	0.417	0.320

GAT 的错误偏向最为集中：8 个任务中 7 个呈现 FP > FN, 表明其注意力机制倾向于将边缘样本推向 ADHD 类别。GT 的错误偏向同样明显 (7 个 FP 偏向任务), 但平均 FP 率最高 (41.7%), 反映其比其他模型更容易产生假阳性。GCN 的错误分布最为均衡：5 个 FP 偏向、2 个 FN 偏向、1 个平衡, 平均 FP 率 (29.1%) 和 FN 率 (31.5%) 在所有模型中均为最低水平。各模型的 FP 率和 FN 率均保持在合理范围内, 未出现极端偏向现象。

表5通过 Cohen’s Kappa 量化了模型两两预测的一致性。

表 5: 模型间预测一致性 (Cohen’s Kappa)

	GCN	GAT	HGNN	HyperGCN	GT
GCN	1.000	0.090	0.126	0.057	0.082
GAT		1.000	0.063	0.101	0.078
HGNN			1.000	0.001	0.023
HyperGCN				1.000	−0.014

整个 Kappa 矩阵的数值范围 (−0.014 至 0.126) 处于 Landis & Koch 量表的“轻微”一致性区间, 意味着**五模型在逐样本预测上高度独立**。即使是范式最接近的模型对——GCN 与 GAT(均为消息传递 GNN), 其 Kappa 也仅 0.090, 表明基于注意力的边加权和基于度的等权聚合确实将模型导向了不同的决策路径。

HyperGCN 与 GT 的 Kappa 为 −0.014, 是唯一接近零值的模型对, 表明两模型在统计上的预测近乎独立。这一独立性具有直接的集成学习意义——两者的多数投票不仅汇总信息, 而且可能抵消对方的系统性错误。

表6从样本难度分层的视角提供了另一维度的互补性证据。

表 6: 样本难度分层统计

任务	困难	中等	简单	困难比例
SLD	11	40	11	0.177
SLI	9	52	5	0.136
SSD	20	39	5	0.312
SSI	19	39	7	0.292
VLD	19	48	6	0.260
VLI	15	55	4	0.203
VSD	18	48	4	0.257
VSI	12	51	9	0.167
平均	15.4	46.5	6.4	0.226

平均 22.6% 的样本被多数模型分类错误 (困难样本), 而仅有 7.6% 被所有模型一致正确分类 (简单样本)。这个不对称的分布揭示了 ADHD fMRI 分类的固有难度: 少数样本处于各模型决策边界的模糊地带。SLI 任务的困难率最低 (13.6%), 与其语言加工 fMRI 信号相对清晰的特征一致。SSD 任务的困难率最高 (31.2%), 短延迟记

忆任务可能对 ADHD 的区分度较弱。VSI 任务呈现独特的分布：12.5%(9 个) 样本为简单样本 (所有模型同时正确), 但 16.7%(12 个) 同时为困难样本, 暗示 VSI 受试者可能分为两个截然不同的子群。

图6以箱线图比较了 Accuracy 与 AUC-ROC 的任务级分布差异。




图 6: 五模型分类能力与排序能力的分布对比

箱线图量化了每个模型的校准间隙: GCN 的 Accuracy 中位数与 AUC-ROC 中位数均处于最高水平, 局部卷积赋予了自然的性能优势; GT 的 Accuracy 和 AUC-ROC 均最低 (Accuracy 约 0.60, AUC-ROC 约 0.66), 但处于合理范围且无明显校准脱节; 各模型在 Accuracy 和 AUC-ROC 上的排序基本一致, 未出现“排序强但分类弱”的分离现象。

综合以上证据链, 第五个核心结论是: **五模型的错误模式具有同质性, 模型间的差异主要体现在绝对性能而非错误类型上。** GCN 在所有指标上均领先, GT 虽位列最末但错误模式与 GCN/GAT 一致。22.6% 的困难样本比例提示, 未来突破可能需要从输入信号质量或更大规模数据入手。

4 分析

4.1 性能排序的深层机制：归纳偏置与样本效率

§3.2 表1呈现了清晰的性能梯队: GCN 领先 (Accuracy 0.701、Macro-F1 0.694), GAT 紧随 (Accuracy 0.664, 差距 0.037), HGNN 和 HyperGCN 居中, GT 位列最后 (Accuracy 0.605)。Friedman 检验确认 Accuracy ($p = 0.015$) 和 AUC-ROC ($p = 0.017$) 差异显著, Nemenyi 事后检验将 GCN/GAT 与 GT 划分为显著差异的两端。

为什么复杂架构未能带来性能提升? 核心原因是**归纳偏置强度**与可用训练数据量的匹配。GCN 对所有邻居取等权平均——这种”局部平滑先验”是最强的结构约束, 在 327 个训练样本条件下有效限制了过拟合。GAT 通过注意力权重松弛了该约

束,引入的少量额外参数转化为约 0.037 的 Accuracy 退化。HGNN 和 HyperGCN 进一步弱化局部性(超边跨邻域连接),自由参数增加在小样本下部分抵消了高阶建模的理论收益。GT 完全解除局部性约束,全局自注意力以 $O(N^2)$ 规模独立学习每对节点的注意力权重,在样本不足时学习到的判别特征不如局部卷积方法稳定。Spearman $\rho = 0.90$ (性能排序与归纳偏置强度的秩相关)为上述解读提供了定量佐证。

4.2 超边建模的优势与陷阱

§3.2 的实验数据显示 HGNN 在各指标上稳居中游(Accuracy 0.651, 排名第三; AUC-ROC 0.729, 排名第三),HyperGCN 紧随其后(Accuracy 0.620, AUC-ROC 0.706)。超图方法整体处于传统 GNN 与 GT 之间的“中间地带”——其高阶建模能力略优于团展开近似的 HyperGCN(AUC-ROC 高出 0.023),但与 GCN/GAT 第一梯队仍存在可量化的差距(Accuracy 差距约 0.05–0.08)。

HyperGCN 与 HGNN 共享超边构建逻辑,区别仅在于将超边展开为团图后运行标准 GCN。团展开近似将超边内的高阶交互退化为两两配对,在 AUC-ROC 上低于 HGNN 达 0.023 (0.706 vs 0.729),Accuracy 差距为 0.031 (0.620 vs 0.651)。这一定量对比直接确认了**完整超图谱卷积相比团展开近似的实质性增益**,但同时也说明即使完整超图卷积,其收益也受限于小样本条件下的归纳偏置需求。综合来看,超边建模的优势(捕获多脑区共激活的高阶信息)和局限(k -NN 构造对噪声的敏感性、小样本下的过拟合风险)同时为实验数据所揭示。

4.3 全局注意力的双面性

Graph Transformer 的实验结果具有重要的教学意义。作为表达上界最高的架构,GT 在所有指标上均排名最末(平均 Accuracy 0.605, AUC-ROC 0.659),与 GCN 的差距在统计上显著(Friedman+Nemenyi, $p < 0.05$)。

但与旧版纯 Transformer 不同,当前 GPS 架构的 GT 各项指标均在合理范围内:所有 8 个任务的 AUC 均高于 0.56, Accuracy 均高于 0.51, 未出现“低于随机猜测”的灾难性失效。从架构机制解释:GT 的全局自注意力消除了**过压缩瓶颈**($O(1)$ 路径长度 vs. 传统 GNN 多跳传播的信号压缩),但代价是**完全丧失“相邻节点功能相关”的局部性先验**。在小样本下这一代价超过了收益,与 Rampasek 等人(2022) [10] 在大规模图基准上归纳偏置-样本效率权衡的结论一致。GPS 混合架构(MPNN+ 全局注意力)相比纯 Transformer 已显著改善了基础性能,但在 40 训练样本级别的脑连接图数据上,局部卷积的归纳偏置仍是决定泛化性能的首要因素。

4.4 局限性

本研究的结论应在以下限制条件下理解:

- (1) **单次数据划分**: 所有实验基于 seed=42 的单次划分, 未进行多折交叉验证。多次划分可进一步增强结论稳健性。
- (2) **模型覆盖不全**: 本研究实现了五种代表性方法, 但未纳入 SAN[13] 等学习型位置编码与注意力结合的混合架构。
- (3) **样本量约束**: 546 名被试在深度学习视角下仍属小样本, 每任务仅 62–74 个样本。这一约束使本研究的核心发现——“归纳偏置在小样本下更有价值”——具有自我强化性: 在更大的数据集上, GT 和 HGNN 等高等表达能力架构的相对性能可能提升。
- (4) **单站点单模态**: 数据来自单一采集站点和单一模态 (rs-fMRI), 研究结论的跨站点泛化性和跨模态 (如结合结构 MRI 或 DTI) 适用性有待验证。
- (5) **静态连接假设**: 图构建基于时间平均的功能连接, 忽略了脑网络动态重组的时间维度。滑动窗动态连接可捕获时变功能状态, 可能对注意力机制类架构 (GAT、GT) 产生差异化增益。

5 结论

本文以 ADHD 检测为统一任务, 系统实现并严格对比了覆盖三类范式的五种图网络算法。主要结论如下:

(1) **归纳偏置强度是小样本场景下泛化性能的关键因素**。GCN 在所有指标上综合排名第一 (Accuracy 0.701, AUC-ROC 0.803), 证实了架构约束强度与样本效率的匹配关系。(2) **模型性能呈清晰的梯队分布**。GCN/GAT 构成第一梯队 (Accuracy 0.664–0.701), HGNN/HyperGCN 居中 (0.620–0.651), GT 位列最后 (0.605), 梯队间的差异在统计上显著 (Friedman $p < 0.05$)。 (3) **全局自注意力在小样本下性能受限**。虽然 GPS 混合架构使 GT 的所有指标保持在合理范围内 (全部 AUC > 0.56), 但与强归纳偏置的 GCN/GAT 仍存在系统性的性能差距。(4) **不同范式的错误模式高度一致**。模型间的低 Kappa 值 (< 0.13) 表明决策路径各异, 但错误类型 (FP/FN 分布) 高度相似, 体现了任务固有难度的一致性。(5) **ADHD 的 fMRI 分类具有内在难度**。22.6% 样本被多数模型分类错误, 未来突破需从输入信号质量或更大规模数据入手。

综上所述, 本研究通过严格的系统性对比实验, 从实验数据出发归纳了不同图网络架构的性能规律与底层机制, 为 fMRI 脑疾病检测的图网络架构选型提供了可验证的实证依据。

团队分工

角色	成员	具体贡献
数据工程	2353721 贾博睿	数据集获取、fMRI 预处理管线构建、特征工程、数据划分、模型理论分析
算法实现	2353815 李昊, 2350223 戴昊晟	GCN/GAT/HGNN/HyperGCN/Graph Transformer 五模型实现、统一训练框架搭建、超参数调优、8 任务 ×5 模型批量训练与 checkpoint 管理
评估与分析	2350284 张俊峰	评估指标体系设计、统计显著性检验、结果可视化、错误分析、报告撰写、项目协调与进度管理

参考文献

[1] Booth, J.R., et al. (2021). Working memory and reward in children with and without ADHD. *OpenNeuro*, ds002424.

[2] Cui, H., et al. (2023). BrainGB: A benchmark for brain network analysis with graph neural networks. *IEEE Trans. Medical Imaging*, 42(2), 493–506.

[3] Jiang, D., et al. (2025). A survey of graph networks for fMRI-based brain disease detection. arXiv preprint.

[4] Yadati, N., Nimishakavi, M., Yadav, P., et al. (2019). HyperGCN: A new method of training graph convolutional networks on hypergraphs. *NeurIPS*.

[5] Xu, K., et al. (2019). How powerful are graph neural networks? *ICLR*.

[6] Alon, U. & Yahav, E. (2021). On the bottleneck of graph neural networks and its practical implications. *ICLR*.

[7] Ji, J., et al. (2022). FC-HAT: Hypergraph attention network for functional brain network classification. *Information Sciences*, 608, 1301–1316.

[8] Feng, Y., et al. (2019). Hypergraph neural networks. *AAAI*.

[9] Dwivedi, V.P. & Bresson, X. (2021). A generalization of transformer networks to graphs. *AAAI Workshop on Deep Learning on Graphs*.

- [10] Rampasek, L., et al. (2022). Recipe for a general, powerful, scalable graph transformer. *NeurIPS*.
- [11] Kipf, T.N. & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *ICLR*.
- [12] Veličković, P., et al. (2018). Graph attention networks. *ICLR*.
- [13] Kreuzer, D., et al. (2021). Rethinking graph transformers with spectral attention. *NeurIPS*.
- [14] Li, X., et al. (2021). BrainGNN: Interpretable brain graph neural network for fMRI analysis. *Medical Image Analysis*, 74, 102233.
- [15] Han, X., et al. (2024). Inter-intra high-order brain network for ASD diagnosis via functional MRIs. *MICCAI*.