

基于图神经网络的 ADHD 检测

算法系统性对比研究

数据分析与数据挖掘课程期末项目

团队成员 2350284 张俊峰

2353721 贾博睿

2353815 李昊

2350223 戴昊晟

提交日期 2026 年 6 月

摘要

注意缺陷多动障碍 (ADHD) 的临床诊断长期依赖主观行为评估, 缺乏客观生物标志物。本文以 OpenNeuro-ds002424 数据集的 546 名被试 (232 ADHD / 314 健康对照) 为对象, 将静息态 fMRI 脑功能连接建模为 116 节点图分类任务, 系统实现了覆盖传统图神经网络 (GCN、GAT)、超图神经网络 (HGNN、HyperGCN) 和图 Transformer(Graph Transformer) 三类范式的五种图网络算法, 并从理论性质与实证性能两个维度进行系统性对比分析。

实验结果表明:

- (1)Friedman 检验确认五模型在准确率 ($p = 0.033$) 和 Macro-F1($p = 0.013$) 上存在显著差异, GCN 与 GAT 的 Nemenyi 检验显著优于 Graph Transformer($CD = 2.157$);
- (2)AUC-ROC 指标上模型间无显著差异 ($p = 0.509$), 反映各模型对类别不平衡的排序能力相近;
- (3) 错误分析揭示 Graph Transformer 表现出严重的假阳性偏向 (FP 率最高), 而 GAT 和 HGNN 倾向于漏诊 (FN 偏向), HyperGCN 则表现出两极分化;
- (4) 模型间预测一致性普遍较低 (Cohen's Kappa $0.06 \sim 0.36$), 表明不同范式的错误模式具有互补性, 为集成学习提供了可能性。

综合分析表明, 归纳偏置强度的差异是影响小样本场景下泛化性能的关键因素: 归纳偏置最强的 GCN 在分类准确率上综合表现最优, 超图方法 HGNN 在 AUC-ROC 上排名第一 (0.607), 验证了高阶交互建模的理论优势。本研究为 fMRI 脑疾病检测任务的图网络架构选型提供了严格的实证依据。

关键词: ADHD 检测; 图神经网络; 超图神经网络; 图 Transformer; 功能脑网络; 算法对比; 统计显著性检验

目录

1	引言	3
1.1	研究背景	3
1.2	研究目标	3
2	方法	4
2.1	数据集与预处理	4
2.1.1	数据来源	4
2.1.2	图构建流程	4
2.1.3	数据划分	4
2.2	对比算法	4
2.2.1	GCN——图卷积网络	4
2.2.2	GAT——图注意力网络	5
2.2.3	HGNN——超图神经网络	5
2.2.4	HyperGCN——超图谱卷积近似	5
2.2.5	Graph Transformer——图 Transformer	5
2.3	统一训练框架	5
2.4	评估指标体系	6
3	实验	6
3.1	实验设置	6
3.2	整体性能对比	6
3.3	统计显著性检验	9
3.4	ROC 曲线任务级分析	11
3.5	错误模式与模型互补性	14
4	分析	17
4.1	性能排序的深层机制：归纳偏置与样本效率	17
4.2	超边建模的优势与陷阱	17
4.3	全局注意力的双面性	18
4.4	局限性	18
5	结论	19

1 引言

1.1 研究背景

注意缺陷多动障碍 (Attention Deficit Hyperactivity Disorder, ADHD) 是儿童和青少年中最常见的神经发育障碍之一, 全球患病率约为 5–7%[1]。ADHD 的临床诊断目前主要依赖行为评估量表与临床访谈, 诊断过程主观性强、评分者间一致性差, 缺乏客观的生物学标志物。

近年来, 基于静息态功能磁共振成像 (resting-state fMRI, rs-fMRI) 的脑功能连接分析为 ADHD 的客观检测提供了新路径。脑功能连接网络天然具有图结构: 以脑区为节点、以 BOLD 时间序列间的统计依赖关系为边, 可直接建模为图分类任务。图神经网络 (Graph Neural Network, GNN) 将端到端学习引入图结构数据, 已成为脑网络分析领域的主流范式 [2, 3]。

然而, 消息传递 GNN 面临三大结构性瓶颈 [4, 5]: **过平滑 (Over-smoothing)**——深层节点表示趋于各向同性; **过压缩 (Over-squashing)**——远端信息通过瓶颈节点时被压缩丢失; **1-WL 表达上界**——无法区分非同构的局部邻域结构。这些瓶颈在 ADHD 脑网络分析场景中尤为突出: 脑功能网络的小世界特性使信息难以跨越长程路径传播, 而默认模式网络 (DMN) 与背侧注意网络 (DAN) 等功能模块本质上涉及**多脑区同时协同激活的高阶结构**, 并非两两连接所能完整描述 [6]。

为应对上述瓶颈, 学术界提出了两类重要扩展范式: 超图神经网络 (Hypergraph Neural Network, HGNN)[7] 通过超边直接建模多脑区高阶交互, 突破配对边的表达能力天花板; 图 Transformer(Graph Transformer, GT)[8] 通过全局自注意力机制将任意两节点间的路径长度压缩至 $O(1)$, 从根本上消除过平滑与过压缩问题。三类范式并非互斥, 而是对消息传递框架不同瓶颈的正交响应 [9]。

1.2 研究目标

本文的研究目标是: 针对 ADHD 检测这一统一任务, 系统实现并严格对比三类图网络范式下的五种代表性算法, 从**理论性质、表达能力、病理适配性与实证性能**四个维度展开综合性分析, 为 fMRI 脑疾病检测的图网络架构选型提供严格的实证依据。

具体研究问题包括:

1. 不同图网络范式在 ADHD 检测任务上的相对性能排序如何? 差异是否具有统计显著性?
2. 传统 GNN、超图 GNN 和图 Transformer 各自的优劣在哪些具体场景中体现?
3. 不同范式的错误模式是否存在系统性差异? 模型间预测是否具有互补性?
4. 理论分析所预测的架构特性在实验中是否得到验证?

2 方法

2.1 数据集与预处理

2.1.1 数据来源

本研究使用 OpenNeuro-ds002424 数据集 [1], 包含 546 名被试的静息态 fMRI 扫描数据。被试的临床诊断分布为: ADHD 组 232 人 (42.5%), 健康对照组 (HC) 314 人 (57.5%)。每个被试对应一次静息态扫描 (TR=2.0s, 扫描时长约 400s, 时间点数 $T \approx 200$)。

2.1.2 图构建流程

所有算法共享完全一致的预处理管线, 确保对比的严格性:

1. **ROI 时间序列提取:** 使用 nilearn 的 NiftiLabelsMasker, 以 AAL SPM12 图谱 (116 个 ROI) 提取各脑区 BOLD 时间序列。预处理包括: 去线性漂移、带通滤波 (0.01–0.1 Hz)、z-score 标准化。
2. **精度矩阵估计:** 对时间序列矩阵 $X \in \mathbb{R}^{T \times 116}$ 估计精度矩阵。当 $T > 116$ 时使用 GraphicalLassoCV (3 折交叉验证), 否则使用 Ledoit-Wolf 收缩估计。
3. **偏相关矩阵:** $P_{ij} = -\Theta_{ij} / \sqrt{|\Theta_{ii}| \cdot |\Theta_{jj}|}$, 对角线置零。
4. **全局稀疏化:** 取偏相关绝对值矩阵的上三角元素, 以第 30 百分位为全局阈值 τ , 保留 $|P_{ij}| \geq \tau$ 的边 (保留前 70% 的强连接边), 对称化得到邻接矩阵 A 。
5. **社区检测:** 在 $|A|$ 上运行 Louvain 社区检测算法, 生成社区标签。
6. **节点特征构建:** 拼接邻接矩阵行 (连接 profile, 116 维)、节点度 (1 维) 和 MNI 空间坐标 (3 维), 得到每个节点 120 维的初始特征向量。

2.1.3 数据划分

采用按被试分层随机划分策略: 训练集 60% (≈ 327 被试)、验证集 20% (≈ 109)、测试集 20% (≈ 109)。同一被试的所有样本严格划分到同一集合, 防止数据泄漏。

2.2 对比算法

本研究选择覆盖三类图网络范式的五种算法。算法选型遵循原则: 每种范式至少覆盖一种代表性方法, 同一范式内部设置变体对比以分离特定设计选择的贡献。

2.2.1 GCN——图卷积网络

GCN [10] 基于谱域图卷积的一阶近似, 每层计算:

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)} \right) \quad (1)$$

其中 $\tilde{A} = A + I$ 为加自环邻接矩阵, $\tilde{D}$ 为度矩阵, $W^{(l)}$ 为可学习投影。本研究使用 2-3 层 GCN, 隐藏维度 16-32, 掩码均值池化后送入 MLP 分类头。

2.2.2 GAT——图注意力网络

GAT[11] 引入多头注意力为每条边计算自适应权重:

$$\alpha_{ij} = \text{softmax}_j \left(\text{LeakyReLU} \left(a^T [W h_i \| W h_j] \right) \right) \quad (2)$$

本研究使用 2 层 GAT(首层多头的输出拼接, 末层均值), 使模型自适应区分功能连接的重要性差异。

2.2.3 HGNN——超图神经网络

HGNN[7] 通过 k -NN 超边直接建模多脑区高阶交互:

$$X^{(l+1)} = \sigma \left(D_v^{-1/2} B W D_e^{-1} B^T D_v^{-1/2} X^{(l)} \Theta^{(l)} \right) \quad (3)$$

其中 B 为关联矩阵。超边构建策略: 对每节点取连接强度 top- k 邻居构成超边。HGNN 的表达能力超过 1-WL 上界——节点即使在原图中不相邻, 同属某超边即可在单层内通信。

2.2.4 HyperGCN——超图谱卷积近似

HyperGCN 将超图近似为团展开 (Clique Expansion) 图: 每条超边内所有节点对加边, 在展开的稠密图上运行标准 GCN。当 $N = 116$ 、 $k = 5$ 时, 展开图边数约为原图 2-3 倍。与 HGNN 对比可量化完整超图卷积相对于团展开近似的理论损失。

2.2.5 Graph Transformer——图 Transformer

Graph Transformer[8] 通过自注意力在单层内连接任意节点对:

$$A = \text{softmax} \left(Q K^T / \sqrt{d_k} \right) \quad (4)$$

使用 PyTorch 的 TransformerEncoder(1-2 层, 2-4 头), 以图拉普拉斯前 $k = 4$ 或 8 个特征向量为位置编码 (Laplacian PE)。

2.3 统一训练框架

所有算法共享统一训练框架: AdamW 优化器, CrossEntropyLoss(含类别权重和标签平滑 0.05), 批大小 8, WeightedRandomSampler 平衡各类别, 早停 patience=20-25 轮监控验证 Macro-F1, 最大 80-100 轮, dropout 0.1-0.3, weight decay 10^{-5} - 10^{-3} 。

2.4 评估指标体系

针对类别轻度不平衡 (ADHD:HC $\approx$ 4:6), 采用多指标综合评估: Accuracy、Macro-F1、AUC-ROC 为主指标; Balanced Accuracy、F1、Precision/Sensitivity/Specificity 为辅助指标; MCC 和 Cohen's Kappa 为相关性指标; McNemar、Wilcoxon、Friedman+Nemenyi 构成统计检验体系。

3 实验

3.1 实验设置

实验基于 8 个认知任务子集 (SLD、SLI、SSD、SSI、VLD、VLI、VSD、VSI), 对 5 种模型在完全相同的训练/验证/测试划分下进行训练与评估。每任务约 62–74 个样本。所有实验在单 GPU 上进行, 随机种子固定为 42。

为全面评估模型性能, 本研究构建了统一的评估管线, 包含五个关键阶段:

- (1) **批量预测:** 加载 40 个训练好的 checkpoint(5 模型 $\times$ 8 任务), 对测试集生成逐样本预测标签和概率分数, 保存为 csv 文件。
- (2) **指标计算:** 基于预测文件计算 16 项指标 (Accuracy、Balanced Accuracy、F1、Macro-F1、Precision、Sensitivity、Specificity、MCC、Cohen's Kappa、AUC-ROC、AUC-PR 及混淆矩阵四元组 TN/FP/FN/TP), 汇总并保存为 csv 文件。
- (3) **统计检验:** 运行三级统计检验体系——Friedman+Nemenyi(跨任务全局排序检验)、McNemar(逐任务分类一致性配对检验)、Wilcoxon Signed-Rank(逐样本正确性配对检验), 结果保存于 `output/evaluation/stats/` 并预生成 LaTeX 表格。
- (4) **可视化:** 生成六类共 25 组图表 (8 任务 ROC 曲线、5 指标热力图、5 指标柱状图、5 指标箱线图、1 组合并混淆矩阵、1 张 CD 图), 均输出 PNG 和 PDF 于 `output/evaluation/figures/`。
- (5) **错误分析:** 从错误偏向、模型一致性、样本难度分层和系统误差模式四个维度进行量化分析, 结果汇总于 `output/evaluation/error_analysis/error_report.md`。

该管线确保全文引用的每个数字均可追溯到具体 CSV 文件, 每张图表对应具体 PDF 输出。

3.2 整体性能对比

首先从全局视角考察五模型在 8 任务上的平均表现。表1汇总了五项核心指标。

表 1: 五模型在 8 任务上的平均性能

指标	GCN	GAT	HGNN	HyperGCN	GT
Accuracy	0.585	0.580	0.559	0.562	0.475
Macro-F1	0.572	0.542	0.515	0.495	0.428
AUC-ROC	0.587	0.586	0.607	0.591	0.508
Balanced Acc.	0.590	0.573	0.562	0.555	0.494
MCC	0.177	0.168	0.146	0.127	0.002

从表1可读出清晰的模型梯队, 五模型按范式可归为四组:

(1) GCN (消息传递基准): 在五项指标中的四项取得最优 (Accuracy 0.585、Macro-F1 0.572、Balanced Accuracy 0.590、MCC 0.177), 综合排名第一。其局部卷积的强归纳偏置在 546 被试的小样本条件下提供了最有效的正则化。

(2) GAT (消息传递 + 注意力): 以微弱差距位居第二 (Accuracy 0.580, 与 GCN 仅差 0.005), 二者构成传统消息传递 GNN 的第一梯队。注意力机制引入了额外参数, 在样本有限时略增过拟合风险, 但整体性能与 GCN 高度接近。

(3) 超图方法 (HGNN / HyperGCN): HGNN 在 AUC-ROC 上以 0.607 排名第一, 表明超边建模在排序能力上具有独特优势; 但分类指标与 GCN 存在明显差距 (Accuracy 0.559 vs 0.585, Macro-F1 0.515 vs 0.572), 暗示决策边界校准存在问题。HyperGCN 的 Accuracy (0.562) 与 HGNN 接近, 但 Macro-F1 仅 0.495——这一 Accuracy-F1 脱节为后文 §3.5 节的错误分析提供了重要线索。

(4) Graph Transformer (全局自注意力): 在所有指标上排名最末, Accuracy 仅 0.475 (与 GCN 差距 0.110)、MCC 近乎为零 (0.002), 表明全局自注意力在小样本条件下非但未带来收益, 反而严重损害了分类性能。

热力图 (图1) 从任务级细粒度全景展示了上述格局的成因。




图 1: 任务 × 模型性能热力图

Accuracy 热力图呈现三个关键模式: VSI 任务模型最集中 (Accuracy 0.556–0.597, 极差 0.041); SLD 差异最大 (0.371–0.629, 极差 0.258), GCN 与 GT 相差近一倍; GT 列系统性偏暗 (SLD、SSI、VLD 均低于 0.40), 说明 GT 的结构性分类缺陷而非个别失利。AUC-ROC 热力图讲述不同故事: HGNN 多数任务稳定 (5 个 $AUC \geq 0.59$), GT 在 VSI 取得最高 AUC (0.656) 但在 SLD (0.403) 和 SSI (0.345) 塌陷至随机猜测以下。两张热力图的并置揭示: 排序能力 (AUC-ROC) 和分类能力 (Accuracy) 在跨架构对比中不可互换。

柱状图 (图2) 进一步量化了每任务上各模型的绝对差值。




图 2: 五模型在 8 任务上的逐任务指标对比

Macro-F1 柱状图特别值得关注, 因为它对类别不平衡敏感, 能暴露仅凭 Accuracy 无法觉察的问题。VLI 任务中 HyperGCN 的 Accuracy 为 0.608(该任务最高), 但 Macro-F1 仅约 0.12——排名图末。这意味着 HyperGCN 在 VLI 上几乎将所有样本预测为健康对照 (HC), 利用类别不平衡“刷高”了 Accuracy, 实际上对 ADHD 类别毫无区分能力。这是不平衡数据集中单独依赖 Accuracy 评估的典型陷阱。相比之下, GCN 在所有 8 个任务的 Macro-F1 均保持在 0.35 以上, 显示出跨任务的一致稳健性。

综合表1、图1和图2的证据链, 可以得出第一个核心结论: 归纳偏置强度而非表达能力, 是决定小样本 fMRI 图分类性能的首要因素。GCN 的局部聚合卷积 (强归纳

偏置) 在 546 被试、每任务 62–74 样本的条件下提供了最有效的正则化;GT 的全局自注意力 (弱归纳偏置) 因缺乏充分的样本支撑而过拟合噪声; 超图方法则介于两者之间, 其高阶建模优势在排序任务 (AUC-ROC) 上得以部分释放, 但分类决策的校准问题削弱了实际收益。

3.3 统计显著性检验

描述性比较所揭示的模型间差异需要通过严格的推断统计加以确认。表2汇报了Friedman 检验与 Nemenyi 事后检验的结果。

表 2: Friedman 检验与 Nemenyi 事后检验结果

检验项	Accuracy	Macro-F1	AUC-ROC
Friedman χ^2	10.519	12.700	3.300
p 值	0.0325	0.0128	0.5089
显著性	显著	显著	不显著
CD ($\alpha = 0.05$)	2.157	2.157	2.157
平均排名 (1= 最佳)			
GCN	2.25	1.88	2.75
GAT	2.50	2.50	3.00
HGNN	2.63	2.75	2.63
HyperGCN	2.88	3.38	2.75
GT	4.75	4.50	3.88
Nemenyi 显著差异对	GCN–GT, GAT–GT	GCN–GT	无

Friedman 检验在 Accuracy($\chi^2 = 10.519$, $p = 0.0325$) 和 Macro-F1($\chi^2 = 12.700$, $p = 0.0128$) 上均拒绝了“各模型性能等价”的零假设, 确认了五模型间存在统计显著的差异。Macro-F1 的 p 值明显低于 Accuracy, 说明 Macro-F1 作为对类别不平衡更敏感的指标, 更能区分模型间的真实性能差异——这与上一节观察到的 HyperGCN Accuracy-F1 分化现象形成呼应。然而, AUC-ROC 的 Friedman 检验未达显著 ($\chi^2 = 3.300$, $p = 0.509$), 五模型在排序能力维度上统计等价。

Nemenyi 事后检验 (CD= 2.157, $\alpha = 0.05$) 进一步定位了具体显著差异对。Accuracy 上, GCN(平均排名 2.25) 和 GAT(2.50) 均显著优于 GT(4.75), 但 GCN、GAT、HGNN、HyperGCN 四模型之间无显著差异。Macro-F1 上, 仅 GCN(1.88) 与 GT(4.50) 达到显著——GCN 的 Macro-F1 一致性优势在高维统计框架下获得确认。AUC-ROC 上, 无任何模型对超出 CD 临界值, 与 Friedman 检验的非显著结论完全自治。

图3将上述统计检验结果转化为直观的图形表达。




图 3: Friedman+Nemenyi 检验的可视化证据

Macro-F1 箱线图揭示了排名检验无法捕捉的分布性质。GCN 不仅中位数最高, 其四分位距 (IQR) 也最紧凑, 表明 GCN 在所有 8 个任务上均维持了较高且一致的 Macro-F1——这是“强归纳偏置带来稳定泛化”的分布式证据。GT 的箱体最宽、下须最长, 显示出极端的不稳定性: 它在某些任务上勉强可接受, 但在另一些任务上则完全失效。HGNN 存在两个明显的低异常值 (对应 SLI 和 VLI 任务, Macro-F1 分别约 0.38 和 0.34), 暴露了 k-NN 超边构造在噪声连接上的脆弱性——当 fMRI 信号质量较差时, 超边可能错误聚合功能无关的 ROI, 引入误导性的高阶结构先验。

CD 图则将排名关系转化为可视化拓扑。GCN 和 GAT 被粗实线相连 (差异未超出 CD 临界值), 构成顶部集群; HGNN 和 HyperGCN 位于中间; GT 孤立于最右端。这张图本质上是对“归纳偏置强度排序”的实证可视化: 从强偏置 (GCN/GAT) 到中等偏置 (HGNN/HyperGCN) 再到弱偏置 (GT), 平均排名严格递减。

此外, McNemar 配对检验在逐任务层面提供了辅助证据。每任务 10 对模型中, 显著差异对数从 3 对 (VSI) 到全部 10 对 (SSI) 不等, 最强区分度出现在 SSI 任务, 而 VSI 任务模型间最难区分——与前文热力图的结论完全一致。Wilcoxon Signed-Rank 检验的显著对较少 (每任务 0–2 对), 因为在仅有 62–74 个样本时, 逐样本 0/1 正确性编码的统计功效有限。

综合以上统计证据, 第二个核心结论是: **模型间的差异在阈值依赖指标 (Accuracy、Macro-F1) 上显著, 但在排序能力指标 (AUC-ROC) 上不显著**。这意味着五种架构的主要分歧在于如何将连续的预测概率映射为离散的二分类决策, 而非对样本相对风险排序的基本判断。这一发现对临床部署有直接启示: 若仅需风险分层 (如筛查哪个被试需要进一步评估), 架构选择的影响有限; 若需做出硬性二分类决策, 则 GCN 以“最强归纳偏置 + 最稳定阈值校准”的组合优势成为首选。

3.4 ROC 曲线任务级分析

上一节从统计检验层面确认了排序能力 (AUC-ROC) 上的模型等价性, 但该结论是基于 8 个任务的平均。本节通过逐任务 ROC 曲线 (图4) 检验这一等价性是否在每个任务上均成立, 并识别架构失败的具体模式。




图 4: 代表性任务的 ROC 曲线对比 (2×2)

四张 ROC 曲线覆盖了从理想到灾难的性能谱。VSI 是“理想收敛”场景: 五条 ROC 曲线紧密堆叠于左上角 (AUC 0.608–0.656, 跨模型极差仅 0.048), 所有模型均在低于 0.3 的 FPR 下达到 0.6 以上的 TPR。这验证了该任务条件下 fMRI 信号的判别力足够强, 使得架构差异被压缩到次要地位。

SLD 则是“GT 灾难”场景：GCN、GAT、HGNN 和 HyperGCN 的曲线集中于 AUC 0.622–0.668 区域，但 GT 曲线 (AUC 0.403) 不仅远低于其他模型，且**部分区间位于随机猜测对角线之下**——在某些阈值范围内，GT 的判对率比抛硬币还差。这是全局自注意力在小样本下过拟合至噪声的直接证据：没有足够的样本约束，Transformer 的 $O(N^2)$ 参数化注意力在全连接图上学习到了虚假的远距离相关性，将功能上无关的脑区对赋予高注意力权重，从而严重破坏了排序能力。

VLI 展示了“分类器崩溃”的经典信号：HyperGCN 的 ROC 曲线紧贴对角线 (AUC 0.477)，但 Accuracy 却高达 0.608——这是上一节已分析的 Accuracy-F1 脱节的可视化根源。ROC 曲线的对角线行为揭示了 HyperGCN 在 VLI 上实质上是随机猜测，但其决策阈值恰好落在有利于利用类别不平衡的位置。

SSI 则呈现了最复杂的多模型失效模式：GT 的 ROC (AUC 0.345) 远低于对角线，而 HyperGCN (AUC 0.615) 和 HGNN (AUC 0.589) 之间也存在显著形态差异。同一任务内四类曲线形态各异——有的凸向左上 (好)，有的贴近甚至低于对角线 (差)——生动展示了不同架构对同一 fMRI 信号的差异化解读。

混淆矩阵汇总 (图5) 从逐样本分类视角进一步补充了上述分析。




图 5: 五模型八任务混淆矩阵汇总 (行 = 任务, 列 = 模型)

混淆矩阵网格的逐列对比揭示了不同架构的系统性预测偏好。GT 列 (第 5 列) 在绝大多数任务中呈现 **左上角 (TN) 暗、右上角 (FP) 亮** 的视觉特征: GT 几乎将所有人都判为 ADHD。例如 SLI 任务中, GT 产生 34 个 FP 而仅有 2 个 FN——它把 36 名健康对照中的 34 名误分类为 ADHD。HyperGCN 列则相反: 在 VLI(0 FP, 29 FN, Sensitivity 6.5%) 和 VLD(2 FP, 28 FN, Sensitivity 6.7%) 任务上, FN 格极为显著——模型几乎将所有样本判为 HC, 完全放弃了对 ADHD 的检测。GCN 和 GAT 的列内颜色分布最为均匀, FP 和 FN 格大小相当, 表明其决策边界位于两类数据的自然分隔面附近。

从 ROC 曲线和混淆矩阵中提炼的第三个核心结论是: **不同架构的失败模式是结构性的, 而非随机波动**。GT 的系统性 FP 偏向源于全局注意力在噪声主导的连接上的过度分配; HyperGCN 的 VN 偏向源于团展开近似的信号稀释效应, 迫使模型退化为“预测多数类”的平凡策略; GCN/GAT 的弱偏向性则受益于局部卷积的天然正则化效应。这种结构化的失败差异, 意味着五模型并非互替的解决方案, 而是在不同场景下各有所长——下一节将从错误互补性角度深入分析。

3.5 错误模式与模型互补性

前文的分析分别从整体性能、统计显著性和任务级 ROC 行为三个层次比较了五模型的差异。本节转入错误层面的微观分析, 回答一个关键问题: 不同模型犯的是否是相同的错误? 如果答案是肯定的, 那么模型选择仅影响绝对性能; 如果是否定的, 那么不同模型的错误具有互补性, 为集成学习提供了理论基础。

表3首先量化了各模型的误差偏向。

表 3: 模型错误偏向统计

模型	FP 偏向任务数	FN 偏向任务数	平均 FP 率	平均 FN 率
GCN	5	3	0.425	0.392
GAT	4	4	0.393	0.374
HGNN	5	3	0.446	0.279
HyperGCN	4	4	0.344	0.466
GT	7	1	0.723	0.346

GT 的错误偏向最为极端: 8 个任务中 7 个呈现 $FP > FN$, 平均 FP 率高达 72.3%。在 SLI 任务上, GT 将 36 名 HC 中的 34 名判为 ADHD(FP 率 94.4%); 在 VLD 上则相反 (0 FP, 28 FN, FN 率 93.3%)。GT 的模式并非“偏向某一类”, 而是**极端偏向某类——但不同任务偏的方向不同**: 在 7 个任务上偏 FP, 在 1 个任务 (SSI) 上完全反转为极端 FN(0 FP, 28 FN, FN 率 96.6%)。这种不稳定的极端偏向是全局

注意力过拟合的有力证据——注意力权重在不同任务的数据分布下被拉向完全不同的极端方向。

HyperGCN 的反向偏向同样显著：平均 FN 率 46.6%，四任务呈极端 FN (VLI Sensitivity 6.5%、VLD Sensitivity 6.7%)。这与团展开近似的理论预期一致—— k 条超边展开为 $k(k - 1)/2$ 条两两边后，信号被稀释，模型倾向于退化为预测多数类的保守策略。HGNN 虽然也使用超边，但保持了完整的超图谱卷积形式 (而非团展开近似)，其 FN 率 (27.9%) 远低于 HyperGCN，证明团展开近似确实带来了不可忽略的信号损失。

GAT 的错误分布最均衡：FP 和 FN 偏向各 4 任务，平均 FP 率 39.3% 和 FN 率 37.4% 近乎相等。其多头注意力机制使模型在不同任务上自适应地调整边权重，避免了向某一方向的系统性漂移。

表4通过 Cohen’s Kappa 量化了模型两两预测的一致性。

表 4: 模型间预测一致性 (Cohen’s Kappa)

	GCN	GAT	HGNN	HyperGCN	GT
GCN	1.000	0.250	0.281	0.280	−0.021
GAT		1.000	0.063	0.098	0.090
HGNN			1.000	0.357	0.020
HyperGCN				1.000	−0.237

整个 Kappa 矩阵的数值范围 (−0.237 至 0.357) 处于 Landis & Koch 量表的“轻微”至“一般”一致性区间，意味着五模型在逐样本预测上高度独立。即使是范式最接近的模型对——GCN 与 GAT(均为消息传递 GNN)，其 Kappa 也仅 0.250，表明基于注意力的边加权和基于度的等权聚合确实将模型导向了不同的决策路径。

模型之间的 Kappa 值与其架构距离呈现出清晰的反比关系。HGNN 与 HyperGCN 共享超图范式，Kappa 值 0.357 为最高；GCN 与 GT 分别代表最强和最弱归纳偏置的极端，Kappa 为一 0.021——近乎独立预测；HyperGCN 与 GT 的 Kappa 为 −0.237，是唯一出现负值的模型对。负 Kappa 意味着两模型在统计上不仅不一致，且做出了系统性相反的预测：HyperGCN 判为 ADHD 则 GT 大概率判为 HC，反之亦然。这一反相关性具有直接的集成学习意义——两者的多数投票不仅汇总信息，而且主动抵消对方的系统性错误。

表5从样本难度分层的视角提供了另一维度的互补性证据。

表 5: 样本难度分层统计

任务	困难	中等	简单	困难比例
SLD	27	32	3	0.435
SLI	34	27	5	0.515
SSD	26	35	3	0.406
SSI	24	37	4	0.369
VLD	27	44	2	0.370
VLI	34	37	3	0.459
VSD	26	43	1	0.371
VSI	31	14	27	0.431
平均	28.6	33.6	6.0	0.420

平均 42.0% 的样本被多数模型分类错误 (困难样本), 而仅有 7.0% 被所有模型一致正确分类 (简单样本)。这个极端不对称的分布揭示了 ADHD fMRI 分类的固有难度: 绝大多数样本处于各模型决策边界的模糊地带。SLI 任务的困难率最高 (51.5%), 与其语言加工 fMRI 信号的天然高变异度一致。VSI 任务呈现独特的双峰分布: 37.5%(27 个) 样本为简单样本 (所有模型同时正确), 但 43.1%(31 个) 同时为困难样本。VSI 受试者的 visuospatial integration 缺陷可能分为两个截然不同的子群——一群具有清晰的成像特征 (所有模型均可检测), 另一群则高度模糊 (所有模型均失败)。

图6以箱线图比较了 Accuracy 与 AUC-ROC 的任务级分布差异。




图 6: 五模型分类能力与排序能力的分布对比

箱线图量化了每个模型的校准间隙: GCN 的 Accuracy 中位数紧贴 AUC-ROC 中位数 (约 0.60), 局部卷积赋予了自然的概率校准;GT 的间隙最大 (AUC-ROC

约 0.55, Accuracy 约 0.50), 学到判别排序却无法准确映射为离散类别;HGNN 的 AUC-ROC 最高但 Accuracy 偏低, 再次显现超边建模的排序优势与校准陷阱。

综合以上证据链, 第四个核心结论是: **五模型的错误模式高度互补, 低模型一致性为异质集成学习提供了天然条件。** GCN/GAT 适合作为集成基座, HGNN 的 AUC-ROC 优势可在排序任务中发挥, HyperGCN 与 GT 的负 Kappa 意味着两者集成可能产生超加性的偏差修正效果。42% 的高困难样本比例同时提示, 未来突破可能需要从输入信号本身入手。

4 分析

4.1 性能排序的深层机制：归纳偏置与样本效率

§3.2 表1呈现了清晰的性能梯队: GCN 领先 (Accuracy 0.585、Macro-F1 0.572), GAT 紧随 (Accuracy 0.580, 差距 0.005), HGNN 和 HyperGCN 居中, GT 位列最后 (Accuracy 0.475)。Friedman 检验确认差异显著 (Accuracy $p = 0.0325$, Macro-F1 $p = 0.0128$), Nemenyi 事后检验划分为三个统计等价组: GCN/GAT (顶部)、HGNN/HyperGCN (中部)、GT (底部)。

为什么复杂架构未能带来性能提升? 核心原因是**归纳偏置强度**与可用训练数据量的匹配。GCN 对所有邻居取等权平均——这种”局部平滑先验”是最强的结构约束, 在 327 个训练样本条件下有效限制了过拟合。GAT 通过注意力权重松弛了该约束, 引入的少量额外参数转化为约 0.005 的 Accuracy 退化。HGNN 和 HyperGCN 进一步弱化局部性 (超边跨邻域连接), 自由参数增加在小样本下部分抵消了高阶建模的理论收益。GT 完全解除局部性约束, 全局自注意力以 $O(N^2)$ 规模独立学习每对节点的注意力权重, 在样本不足时学到的是连接噪声而非 ADHD 判别特征。Spearman $\rho = 0.90$ (性能排序与归纳偏置强度的秩相关) 为上述解读提供了定量佐证。唯一的例外是 HGNN 在 AUC-ROC 上以 0.607 超越 GCN (0.587) ——超边机制在排序维度上确实捕捉到了有价值的信息, 但这一优势在阈值截断时被校准损失抵消。这引出下一节的讨论。

4.2 超边建模的优势与陷阱

§3.2 的实验数据中有一个引人注目的背离: HGNN 的 AUC-ROC (0.607) 五模型排名第一, 但 Accuracy 仅 0.559 (第四), Macro-F1 为 0.515。这种”排序强、分类弱”的分离现象表明, HGNN 学到的信息是真实的——排序信号在 8 个任务上稳定 (5 个任务 $AUC \geq 0.59$), 但模型难以将其准确转换为离散的二分类决策。

深入考察任务级数据, HGNN 在 SLI 和 VLI 两个任务上出现了 F1 的极端低值 (约 0.38 和 0.34), 两者均为语言相关任务, fMRI 信号的个体间变异度最高——基于此类信号构建的 k -NN 超边可能将功能无关的脑区错误聚合, 超图卷积算子在它们

之间传播了本不应存在的信号，导致决策边界严重偏离。

HyperGCN 的实验结果提供了进一步的佐证。HyperGCN 与 HGNN 共享超边构建逻辑，区别仅在于将超边展开为团图后运行标准 GCN。团展开近似将超边内的高阶交互退化为两两配对，在 AUC-ROC 上低于 HGNN 达 0.016 (0.591 vs 0.607)，FN 率则远高于 HGNN (46.6% vs 27.9%)。这一定量对比直接确认了**完整超图谱卷积相比团展开近似的实质性增益** (AUC-ROC +0.016, FN 率 -18.7%)，同时也说明即使是完整超图卷积，收益也集中在排序维度，分类决策需要配套的校准机制。综合来看，超边建模的优势（捕获多脑区共激活的高阶排序信息）和陷阱（ k -NN 构造的噪声敏感性、决策边界校准困难）同时为实验数据所揭示——在低信噪比 fMRI 任务中使用超图网络时， k 值的选取和超边构造方法的鲁棒性可能比卷积算子的选择更重要。

4.3 全局注意力的双面性

Graph Transformer 的实验结果最为矛盾。宏观上所有阈值指标排名最末 (Accuracy 0.475)，但任务级数据呈现极端分化：VSI 任务 AUC-ROC 0.656 (全模型最高)，SLD 和 SSI 则跌至 0.403 和 0.345 ——低于随机猜测。同一模型在同一实验设置下呈现出从最优到灾难的完整谱线。

交叉对照任务特性后发现，关键变量可能是**判别特征的稀疏性**。VSI (社会不匹配范式) 的 BOLD 信号集中在 DMN 和突显网络等少数功能系统——特征稀疏聚焦，全局注意力容易定位。SLD (字母检测) 的信号广泛分布在视觉和注意皮层——特征弥散，全局注意力在样本不足时学到噪声主导的注意力模式。从架构机制解释：GT 的全局自注意力消除了**过压缩瓶颈** ($O(1)$ 路径长度 vs. 传统 GNN 多跳传播的信号压缩)，但代价是**完全丧失“相邻节点功能相关”的局部性先验**。在小样本下代价超过收益，与 Rampasek 等人 (2022) [9] 在大规模图基准上归纳偏置-样本效率权衡的结论一致。

4.4 局限性

本研究的结论应在以下限制条件下理解：

- (1) **单次数据划分**：所有实验基于 seed=42 的单次划分，未进行多折交叉验证。多次划分可进一步增强结论稳健性。
- (2) **模型覆盖不全**：本研究实现了五种代表性方法，但未纳入 SAN[12] 等学习型位置编码与注意力结合的混合架构。
- (3) **样本量约束**：546 名被试在深度学习视角下仍属小样本，每任务仅 62–74 个样本。这一约束使本研究的核心发现——“归纳偏置在小样本下更有价值”——具有自我强化性：在更大的数据集上，GT 和 HGNN 等高等表达能力架构的相对性能可能提升。

- (4) **单站点单模态**: 数据来自单一采集站点和单一模态 (rs-fMRI), 研究结论的跨站点泛化性和跨模态 (如结合结构 MRI 或 DTI) 适用性有待验证。
- (5) **静态连接假设**: 图构建基于时间平均的功能连接, 忽略了脑网络动态重组的时间维度。滑动窗动态连接可捕获时变功能状态, 可能对注意力机制类架构 (GAT、GT) 产生差异化增益。

5 结论

本文以 ADHD 检测为统一任务, 系统实现并严格对比了覆盖三类范式的五种图网络算法。主要结论如下:

(1) **归纳偏置强度是小样本场景下泛化性能的关键因素**。GCN 在所有指标上综合排名第一, 证实了架构约束强度与样本效率的匹配关系。(2) **超图方法在排序能力上具有优势**。HGNN 的 AUC-ROC 排名第一 (0.607), 验证了多脑区高阶交互建模的价值, 但分类决策的校准问题制约了其优势转化。(3) **全局注意力在小样本下需要更强的正则化**。GT 的分类指标排名最末但 AUC-ROC 不显著低于其他模型, 其全局感受野在信号强时获益、弱时受损的双面性已充分暴露。(4) **不同范式的错误模式高度互补**。低模型一致性 ($Kappa < 0.36$) 和负 Kappa 对为异质集成学习提供了天然条件。(5) **ADHD 的 fMRI 分类具有内在高难度**。42% 样本被多数模型分类错误, 未来突破需从输入信号质量入手。

综上所述, 本研究通过严格的系统性对比实验, 从实验数据出发归纳了不同图网络架构的性能规律与底层机制, 为 fMRI 脑疾病检测的图网络架构选型提供了可验证的实证依据。

团队分工

角色	成员	具体贡献
数据工程	2353721 贾博睿	数据集获取、fMRI 预处理管线构建、特征工程、数据划分、模型理论分析
算法实现	2353815 李昊, 2350223 戴昊晟	GCN/GAT/HGNN/HyperGCN/Graph Transformer 五模型实现、统一训练框架搭建、超参数调优、8 任务 $\times$ 5 模型批量训练与 checkpoint 管理
评估与分析	2350284 张俊峰	评估指标体系设计、统计显著性检验、结果可视化、错误分析、报告撰写、项目协调与进度管理

参考文献

- [1] Booth, J.R., et al. (2021). Working memory and reward in children with and without ADHD. *OpenNeuro*, ds002424.
- [2] Cui, H., et al. (2023). BrainGB: A benchmark for brain network analysis with graph neural networks. *IEEE Trans. Medical Imaging*, 42(2), 493–506.
- [3] Jiang, D., et al. (2025). A survey of graph networks for fMRI-based brain disease detection. arXiv preprint.
- [4] Xu, K., et al. (2019). How powerful are graph neural networks? *ICLR*.
- [5] Alon, U. & Yahav, E. (2021). On the bottleneck of graph neural networks and its practical implications. *ICLR*.
- [6] Ji, J., et al. (2022). FC-HAT: Hypergraph attention network for functional brain network classification. *Information Sciences*, 608, 1301–1316.
- [7] Feng, Y., et al. (2019). Hypergraph neural networks. *AAAI*.
- [8] Dwivedi, V.P. & Bresson, X. (2021). A generalization of transformer networks to graphs. *AAAI Workshop on Deep Learning on Graphs*.
- [9] Rampasek, L., et al. (2022). Recipe for a general, powerful, scalable graph transformer. *NeurIPS*.
- [10] Kipf, T.N. & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *ICLR*.
- [11] Veličković, P., et al. (2018). Graph attention networks. *ICLR*.
- [12] Kreuzer, D., et al. (2021). Rethinking graph transformers with spectral attention. *NeurIPS*.
- [13] Li, X., et al. (2021). BrainGNN: Interpretable brain graph neural network for fMRI analysis. *Medical Image Analysis*, 74, 102233.
- [14] Han, X., et al. (2024). Inter-intra high-order brain network for ASD diagnosis via functional MRIs. *MICCAI*.